Eine Einführung in Versionverwaltungsysteme

Wissenswertes für GIT-Anwender

bernd.wunder@leb.eei.uni-erlangen.de

Lehrstuhl für Elektronische Bauelemente
Friedrich-Alexander-Universität Erlangen-Nürnberg

23. Februar 2012

Inhaltsverzeichnis

Einführung

- Was ist ein Versionsverwaltungssystem?
- Warum Versionsverwaltung?
- Übersicht über VCS
- Warum Git?
- Grundbegriffe

Was ist ein Versionsverwaltungssystem

> *Eine Versionsverwaltung ist ein System, das zur Erfassung von Änderungen an Dokumenten oder Dateien verwendet wird. Alle Versionen werden in einem Archiv mit Zeitstempel und Benutzerkennung gesichert und können später wiederhergestellt werden.* [1]

Aufgaben

- Protokollierungen der Änderungen
- Wiederherstellung von alten Ständen
- Archivierung der einzelnen Stände eines Projektes
- Kooperative Entwicklung (Entwicklungsteams)
- gleichzeitige Entwicklung mehrerer Entwicklungszweige (branches)

[1] Quelle: Wikipedia

Warum Versionsverwaltung?

1. viele gleichzeitige laufende Projekte / Features (z.B. Sicherheitsupdates, neue Funktionstests, verschiedene Versionen)
2. Um des Chaos Herr zu werden

Warum Versionsverwaltung?

1. viele gleichzeitige laufende Projekte / Features (z.B. Sicherheitsupdates, neue Funktionstests, verschiedene Versionen)
2. Um des Chaos Herr zu werden
3. Überblick über die gesamte Entwicklung behalten
4. kolaboratives Arbeiten in einem Team

Übersicht über Versionsverwaltungssysteme

engl. Bezeichnungen: *Version Control System (VCS)*, *Software Configuration Management (SCM)*, *Revision Control System (RCS)*

Ein bisschen über die **Geschichte** von VCS:

- Marc J. Rochkind: Source Code Control System (1972)
- Walter F. Tichy: Revision Control System (1980)
- Dick Grune: Concurent Control System (1985)
- Brian Berliner: Neu in C geschrieben, wurde später zur GNU CVS Version (1990)
- Karl Fogel, Jim Blandy, Ben Collins-Sussman: Subversion (2000)
- Linus Torvalds: Git (2005)
- Junio C Hamano: GIT — a stupid content tracker

Übersicht über Versionsverwaltungssysteme

unvollständige Übersicht einiger VCSe:

Revision Control System (RCS)

Entwicklung:	1980 bis 2004
Einteilung:	lokales, dateibasiertes VCS
Probleme:	Binärdateien, Verzeichnisse, locks, merge, keine Atomic commits, keine Metadaten, umbenennen
Lizenz:	GPL2
Betriebssysteme:	UNIX, WIN95

Entwickelt für die Versionsverwaltung von Text-Dateien auf einem Computer! RCS ist im Wesentlichen mit dem ersten VCS, dem *Source Code Control System (SCCS)*, vergleichbar.

Versionsverwaltungsysteme

Concurrent Versions System (CVS)

basierend auf:	RCP (nutzt gleiches Speicherformat)
Entwicklung:	1989 bis 2008
Einteilung:	zentrales VCS
Probleme:	Binärdateien, Verzeichnisse, locks, merge, keine Atomic commits, keine Metadaten, umbenennen
Lizenz:	GPL2
Betriebsysteme:	UNIX, WINDOWS, Mac OS X

CVS wird nicht mehr aktiv weiterentwickelt. Die offizielle Webseite wird nicht mehr weiter betreut. [a]

[a] Quelle: Wikipedia

Versionsverwaltungsysteme

Subversion (SVN)

basierend auf:	CVS (Nachfolger)
Entwicklung:	seit 2000
	Ziele CVS Probleme (siehe oben) zu beseitigen
Einteilung:	zentrales VCS
Probleme:	Binärdateien, Verzeichnisse, locks, merge
Lizenz:	Apache License
Betriebsysteme:	UNIX, WINDOWS, Mac OS X

Subversion versteht sich als Weiterentwicklung von CVS und entstand als Reaktion auf weit verbreitete Kritik an CVS. In der Bedienung der Kommandozeilenversion ist es sehr ähnlich gehalten. [a]

[a] Quelle: Wikipedia

Git

Die Entwicklung von Git wurde im April 2005 von Linus Torvalds begonnen, um das bis dahin verwendete Versionskontrollsystem BitKeeper zu ersetzen, das durch eine Lizenzänderung vielen Entwicklern den Zugang verwehrte. Die erste Version erschien bereits wenige Tage nach der Ankündigung. Derzeitiger Maintainer von Git ist Junio Hamano.

1. Nicht-lineare Entwicklung
2. Kein zentraler Server
3. Datentransfer zwischen Repositories
4. Kryptographische Sicherheit der Projektgeschichte
5. Interoperabilität
6. Web-Interface

Linus Torvalds ist Initiator von Git und des Kernels Linux

Vergleich[2] einiger Versionsverwaltungsysteme

Vergleich | CVS,SVN,GIT,Mercurial

Operation	**CVS**	**SVN**	**GIT**	**Mercurial**
Atomic Commits:	Nein	Ja	Ja	Ja
Umbenennen/Verschieben von Dateien und Verzeichnissen:	Nein	Ja	Ja	Ja
Intelligente Merges nach Umbenungen/Verschiebungen:	Nein	Nein	Nein	Ja
Verzeichnisse/Dateien mit History im Repository kopieren:	Nein	Ja	Nein	Ja
Remote Kopie in lokales Verzeichnis:	Nein	Nein	Ja	Ja
Änderungen an andere Repository weitergeben:	Nein	Nein	Ja	Ja
Changesets Support	Nein	teilw.	Ja	Ja

[2] Quelle: Version Control System Comparison

Warum Git?

Speed Schnellstes mir bekannte Versionsverwaltungssystem

Branch sehr einfach Zweige (Branch) zu erstellen und zusammenzuführen!

Lokal alle Informationen sind lokal gespeichert, keine Netzwerkverbindung notwendig!

Speicher sehr geringer Speicherverbrauch durch Kompression

	Git	Hg	Bzr
Init	0.024s	0.059s	0.600s
Add	8.535s	0.368s	2.381s
Status	0.451s	1.946s	14.744s
Diff	0.543s	2.189s	14.248s
Tag	0.056s	1.201s	1.892s
Log	0.711s	2.650s	9.055s
Commit (Large)	12.480s	12.500s	23.002s
Commit (Small)	0.086s	0.517s	1.139s
Branch (Cold)	1.161s	94.681s	82.249s
Branch (Hot)	0.070s	12.300s	39.411s

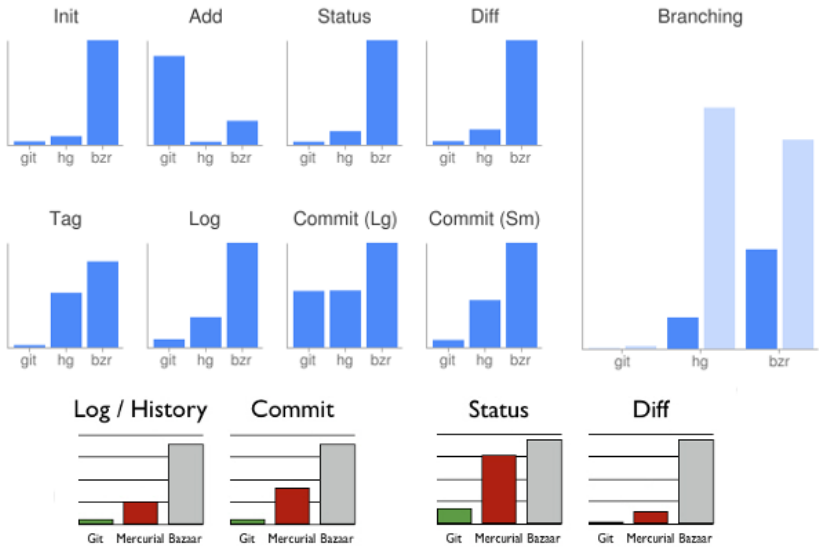

Abbildung: Geschwindigkeitsvergleich von Git, Mercuial und Baszar

Warum Git?

Protokoll http, https, ssh, git, ...

Kooperativ gute Zusammenarbeit mit anderen Versionsverwaltungssystemen. Z.B. mit SVN oder CVS

Stabil sehr aktives Projekt mit vielen hundert Entwicklern

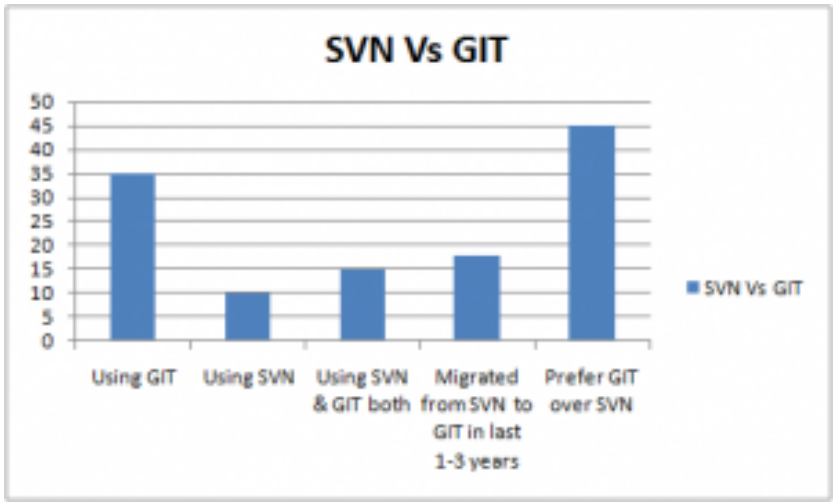

Abbildung: Geschwindigkeitsvergleich von Git, Mercuial und Baszar

Warum Git?

tested Protokiv im Einsatz bei Linux-Kernel (>1000 Entwickler)

me ... i know about it and i *really like it* ;-)

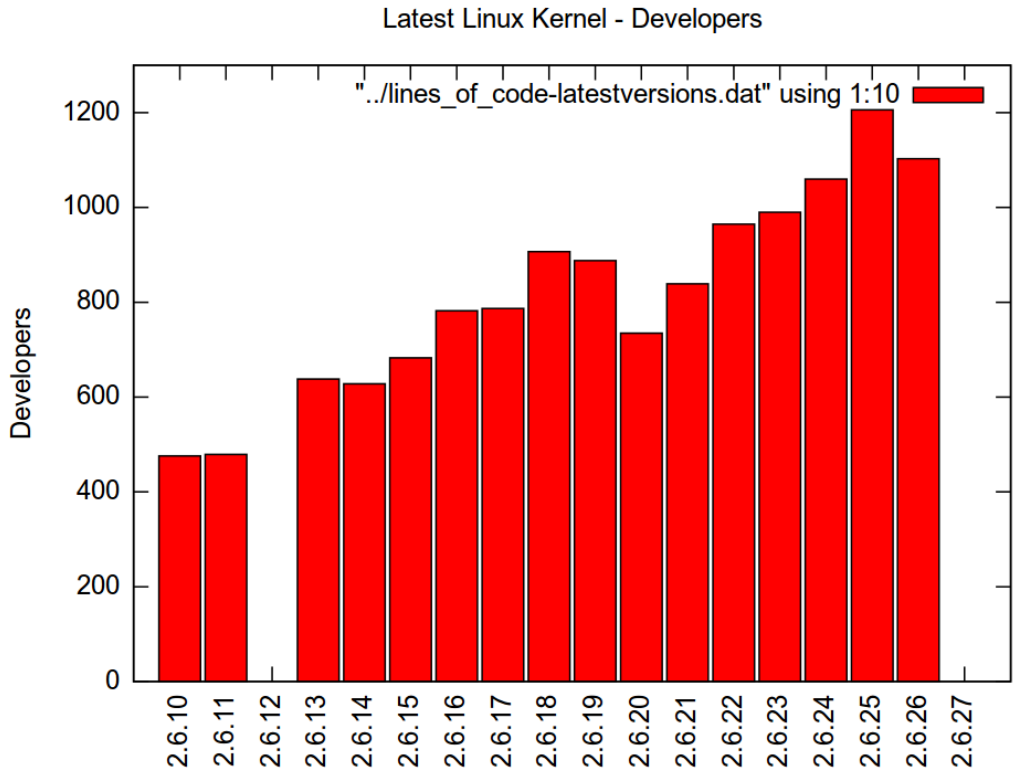

Abbildung: Übersicht[3] über die Anzahl der Linux Kernel Entwickler

[3] Quelle: Michael Schönitzer

Warum Git?

Wer nutzt Git?

Viele Open Source Projekte setzen bereits Git ein:
(umfangreiche Liste auf git.wiki.kernel.org)

- Linux Kernel
- Git
- Android (Google's Handy OS)
- CakePHP (PHP Framework)
- Debian - Linux Distribution
- Drupal - CMS System
- Typo3 - CMS System
- Perl
- Ruby on Rails
- VLC
- PostgreSQL
- KDE
- Fluxbox
- X.Org
- GCC (Gnu Compiler Collection)
- JQuery (JavaScript library)
- Qt (Cross-platform graphic toolkit)
- Eclipse
- Gnome
- ...

Grundbegriffe

Repository

Datenbank in dem jeder Dateistand eines Projektes über die Zeit hinweg gespeichert ist.

Working Tree

Arbeitsverzeichnis in dem die Modifikationen durchgeführt werden.

Commit

beinhaltet alle Veränderungen bzw. spiegelt den aktuellen Zustand der in das VCS aufgenommen werden soll wieder. Enthält neben den Änderungen zusätzliche Metadaten (Commit Message, Autor, Datum, Signatur, ...)

HEAD

zeigt auf die neueste Version *Kopf* im aktuellen Zweig (Branch)
Achtung: Unterschide zwischen GIT und SVN,CVS

Grundbegriffe

Secure Hash Algorithm (SHA-1)

ist eine eindeutige, 160 Bit (40 hexadezimale Zeichen) lange Prüfsumme für beliebige digitale Informationen.

Beispiel:

mit dem GNU/Linux Programm *sha1sum* wird die Prüfsumme für den Text *"Isabella und Lilly Wunder"* berechnet werden:

```
bernd@Power:~$ echo "Isabella und Lilly Wunder" | sha1sum
25989877d4888b5a4f41850069a7c53ac2c8e3ff  -
```

Grundbegriffe (GIT)

Branch

bezeichnet einen parallelen Entwicklungszweig. Der Hauptzweig in einem Versionsverwaltungssystem hat meistens einen speziellen Namen. (z.B in SVN->*trunk* und in GIT->*master*)

Objektmodell

Git-Objekte (blob, tree, commit, tag) sind in einer Objektdatenbank gespeichert und über SHA1-Summen identifizierbar. Die History eines Repository lässt sich als Graph von Objekten modellieren.

Grundbegriffe (GIT)

Index

Der *Index* ist ein lokaler Zwischenspeicher. Alle Änderungen werden zuerst in den index geschrieben. Anschießend wird der Index durch einen *commit* in das Repository eingecheckt.

Clone

ist eine Kopie eines Repositories mit der gesamten History der Entwicklung.

Tag

Ein Tag ist ein symbolischer Name für schwer zu merkende SHA-1 Summen. So können spezielle *Commit* einen Namen, also ein *Tag* erhalten.

Grundlagen und die Git Konzepte

- Lokale, zentrale und verteilte Versionsverwaltungssysteme
- Zentral VS Dezentral
- Workflows
- Der Index
- Objektmodel in Git
- History

Lokale, zentrale und verteilte Versionsverwaltungssysteme

lokal rcs: einfache Ergänzung des Dateisystems.

zentral Subversion (SVN), CVS: Kommunikation nur über zentralen Server.

verteilt Git, Baszar, Merkurial: Kommunikation beliebig.

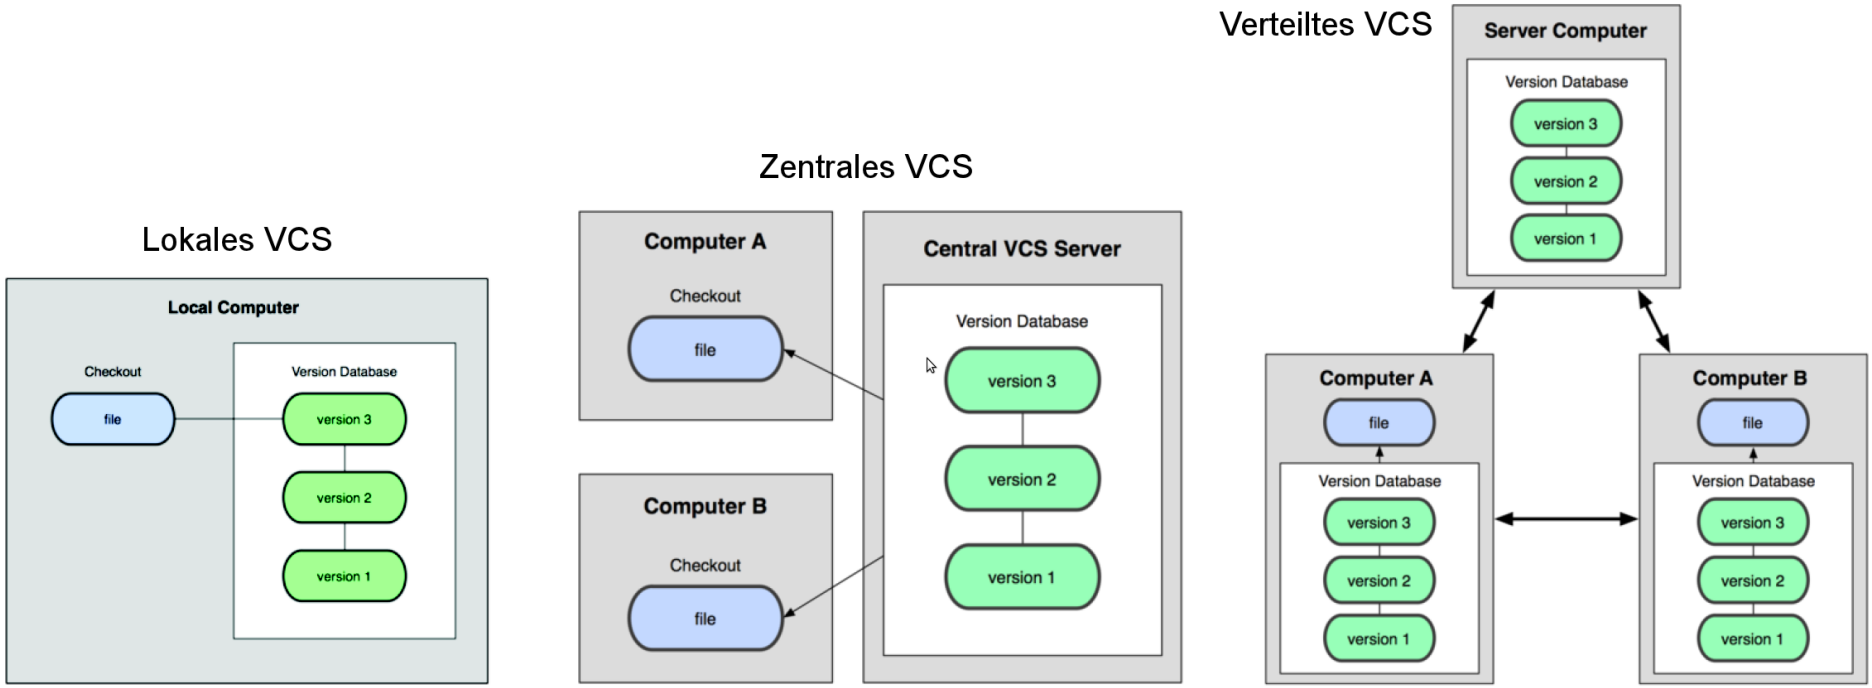

Abbildung: Unterschiedliche Arten von Versionsverwaltungssystemen [4]

[4] Quelle: Pro Git - Scott Chacon

Wie speichern VCS meine Daten?

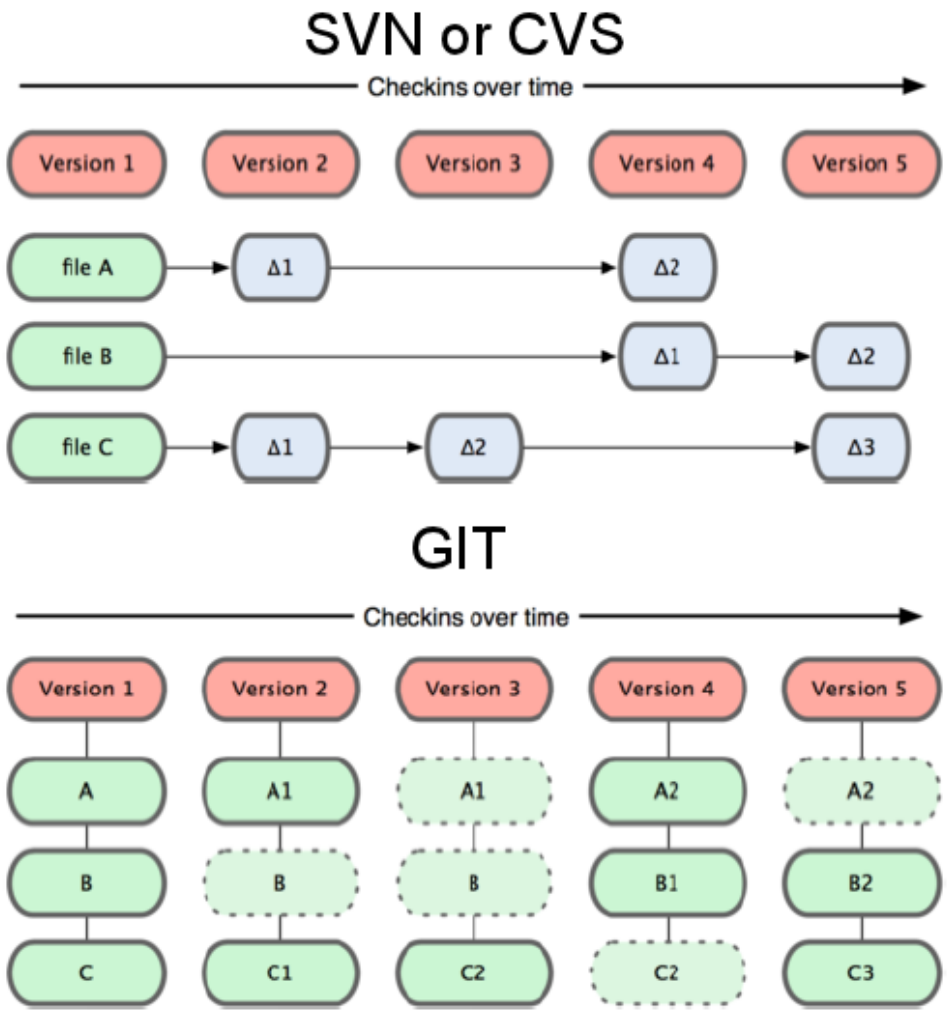

Abbildung: Subversion, CVS speichern nur die Unterschiede (diffs), Git speichert Snapshots

Die Kathedrale und der Basar

Der legendäre Artikel *The Cathedral and the Bazaar (1997)* von Eric S. Raymond vergleicht zwei verschiedene Entwicklungskonzepte für Software.

- **Basar**: Ein großer Marktplatz voller Entwickler, keine vorwiegende Struktur erkennbar.
- **Kathedrale**: Entwickler folgen der geistigen Führung in einer sehr hierachischen Struktur.
- Linus Torvalds nutzte als erster die Basar Struktur zur Entwicklung des Linux Kernels
- Ein Beispiel für eine Kathedrale ist die Struktur der Windows Entwicklung
- es gibt auch gemischte Strukturen , z.B. wird der MATLAB Core in einer Kathedrale und die Toolboxen auf dem Basar entwickelt
- ESR war über den extrem schnellen Erfolg des Basars verwundert. Lag der Erfolg an der Struktur oder Linus, ...?
- ESR zeigt anhand von *fetchmail* (früher: *popclient*) die Vorteile von einem Basar auf, siehe Artikel!

Abbildung: Eric S. Raymond (ESR) ist ein US-amerikanischer Autor und Programmierer in der Open-Source-Szene

Zentral VS Dezentral

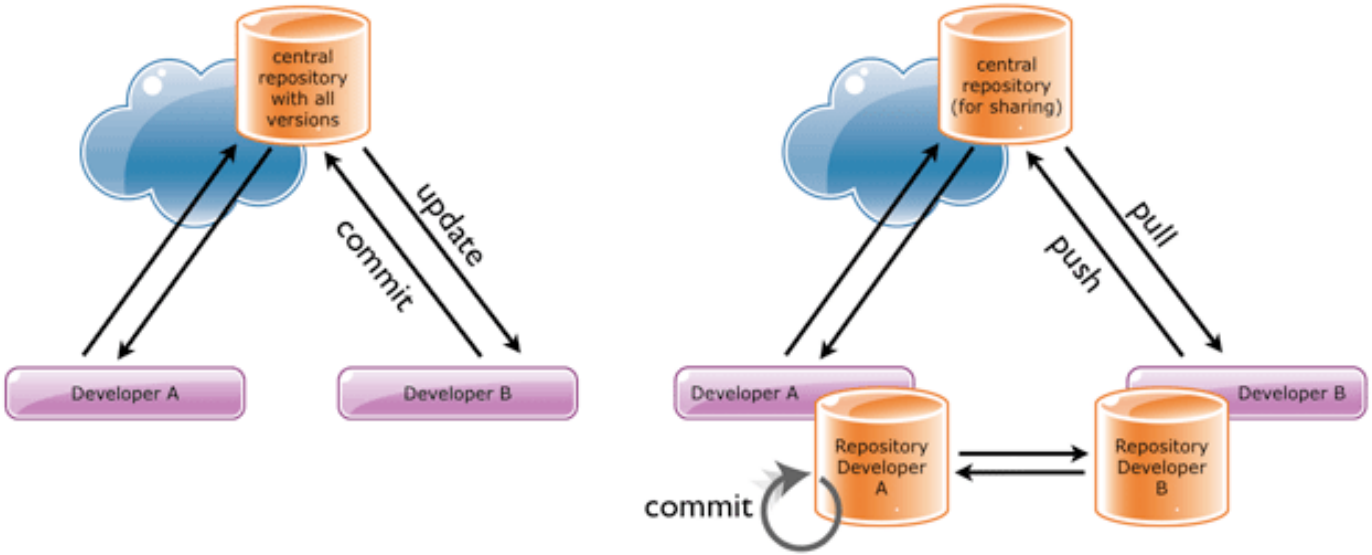

Zentrales VCS

- Preformance und Skalierbarkeit hängig von vom Server ab
- Hohe Serverbelastung
- Single Point of Failure
- Backups sehr Wichtig!
- Hoher Administationsaufwand
- Verbindung zu Server notwendig um VCS nutzen zu können.

Dezentrales VCS

- deutlich geringer Serverbelastung beim *zentralen* Speicher
- jeder Entwickler hat die Komplette Versionsgeschichte local
- Administationsaufwand je nach verwendeter Architektur deutlich geringer
- **keine** Verbindung zu Server notwendig um VCS nutzen zu können.
- kann z.B. mit der Portablen Version von Git sogar ohnen Ädmin"Rechte installiert und verwendet werden.

Zentral AND Dezentral

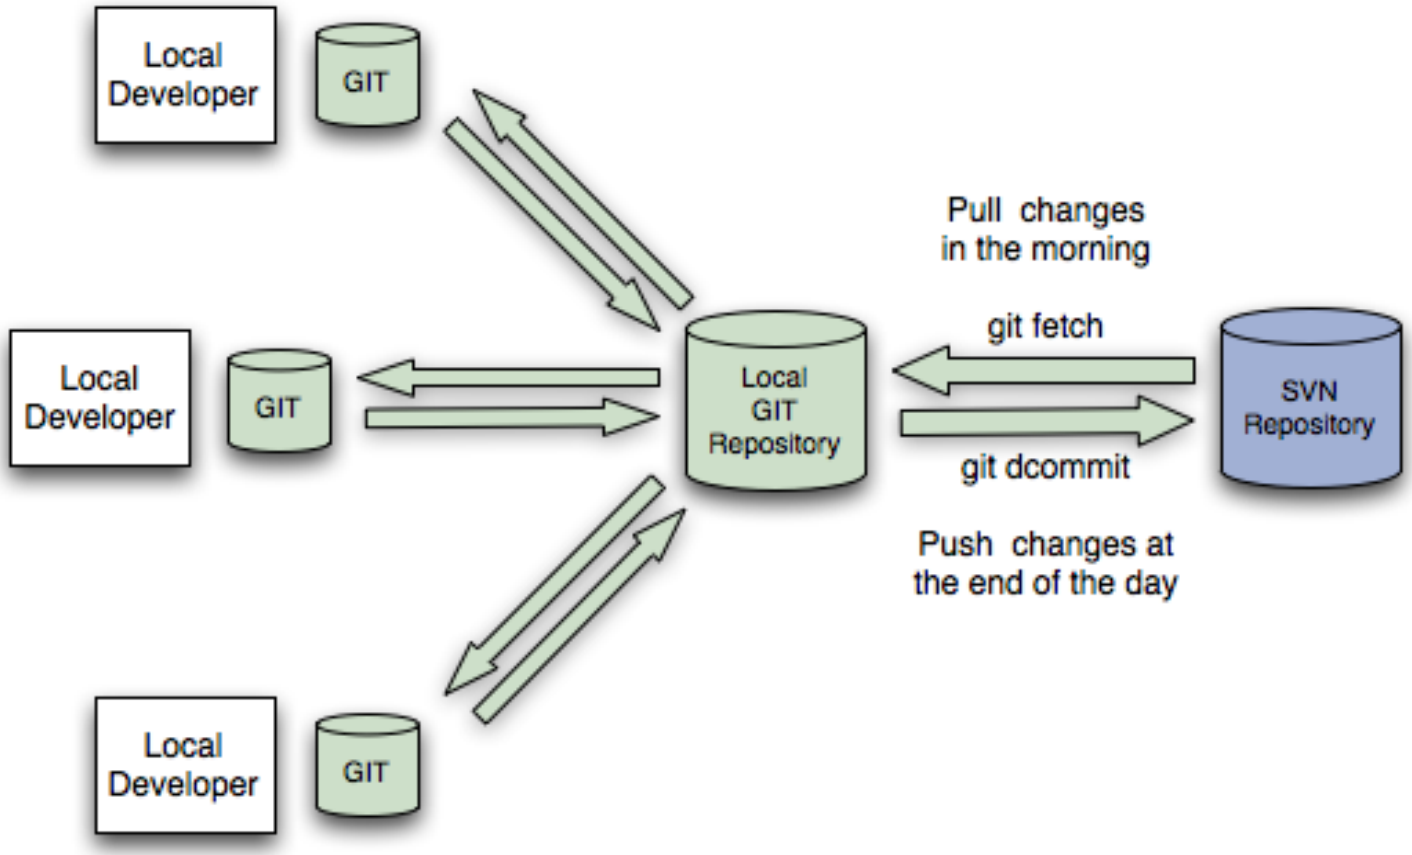

Workflows

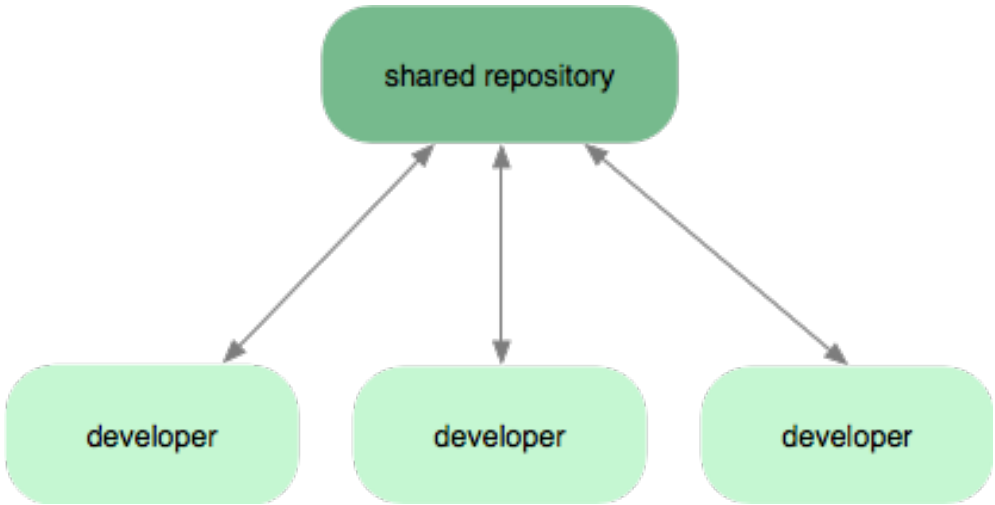

Workflows

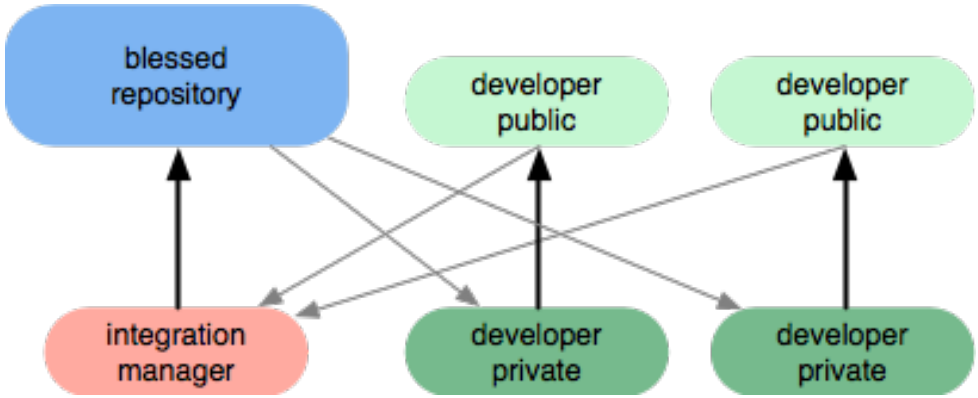
blessed repository
developer public
developer public
integration manager
developer private
developer private

Workflows

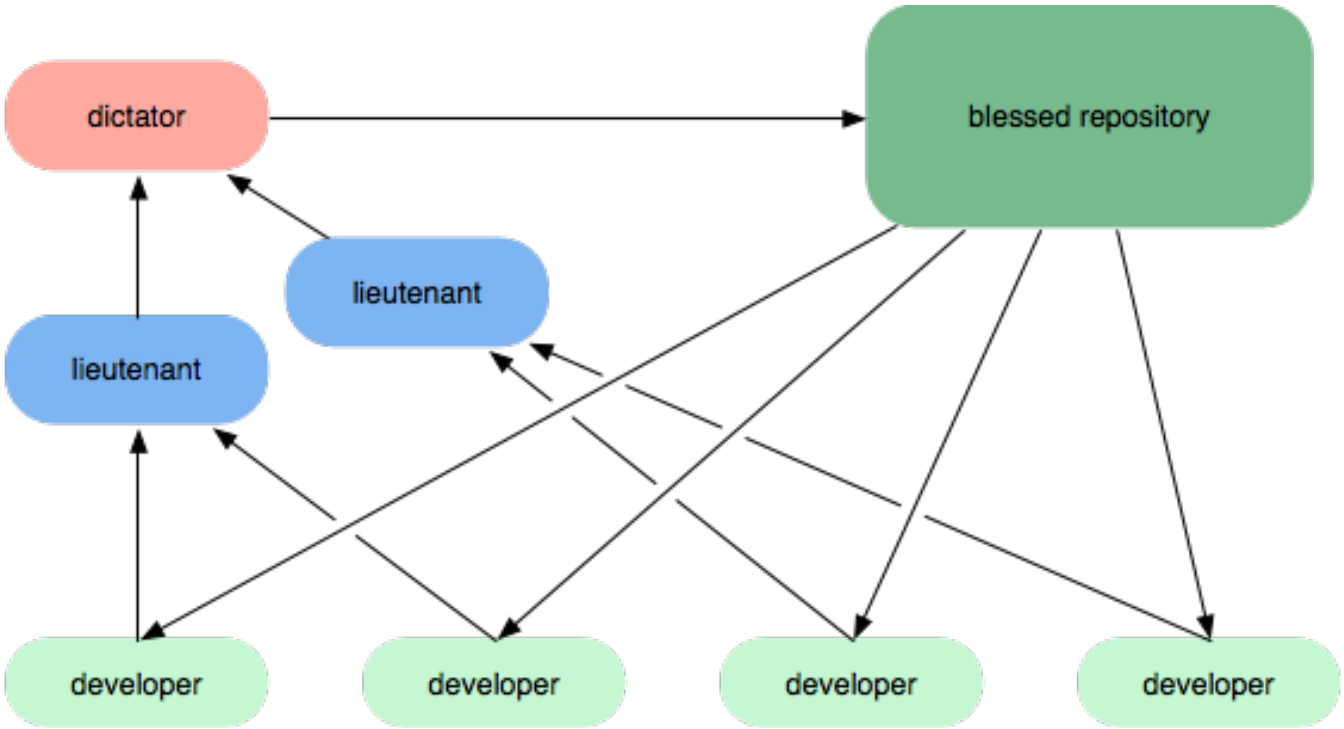
dictator
blessed repository
lieutenant
lieutenant
developer
developer
developer
developer

Der Index

Der Index

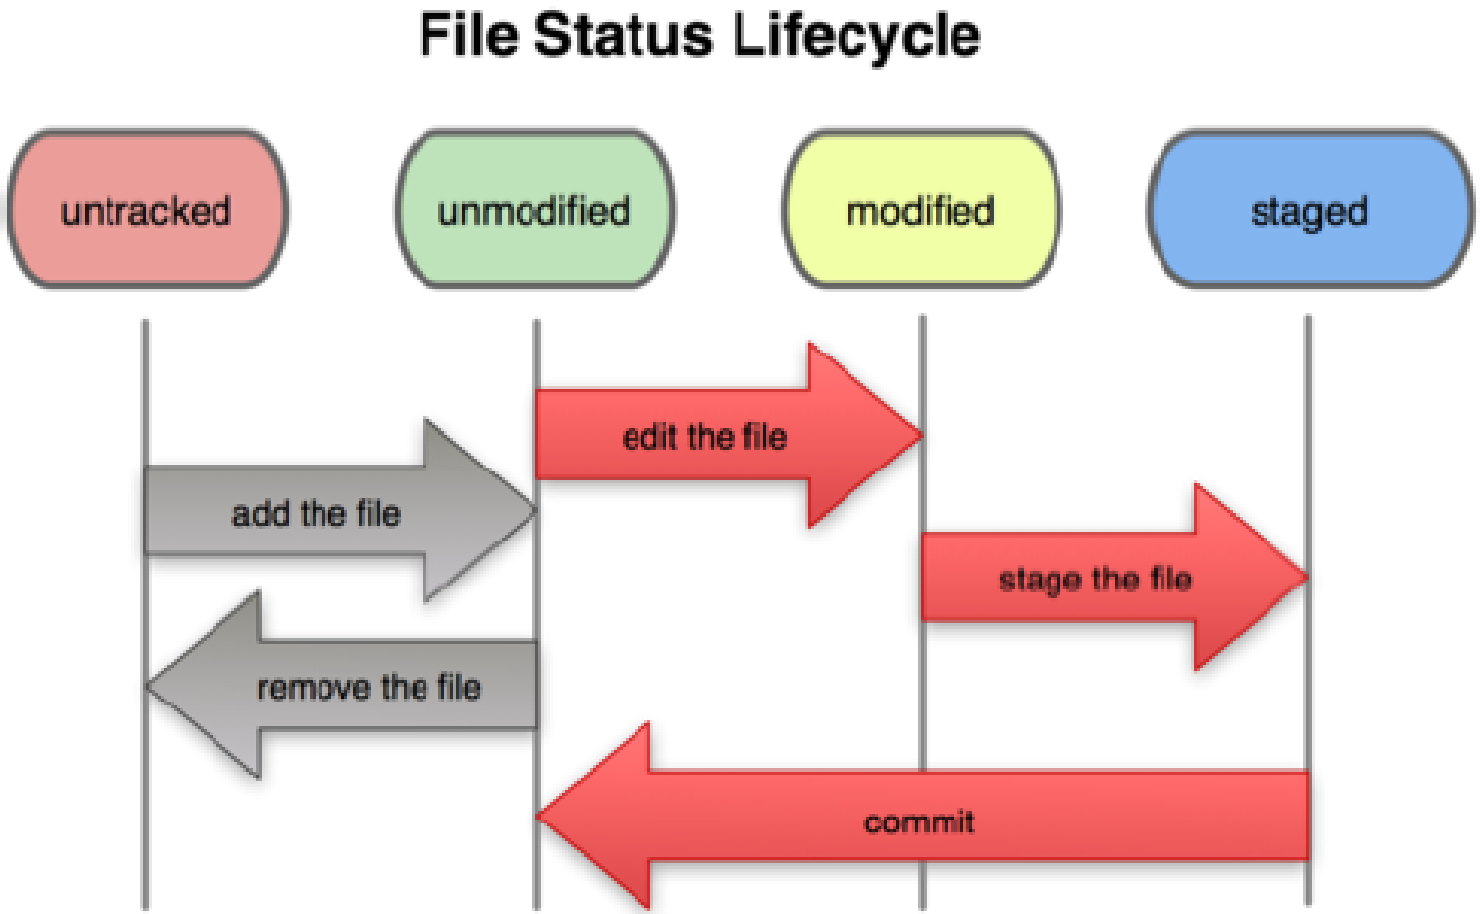
File Status Lifecycle
untracked
unmodified
modified
staged
edit the file
add the file
stage the file
remove the file
commit

Objekte in Git

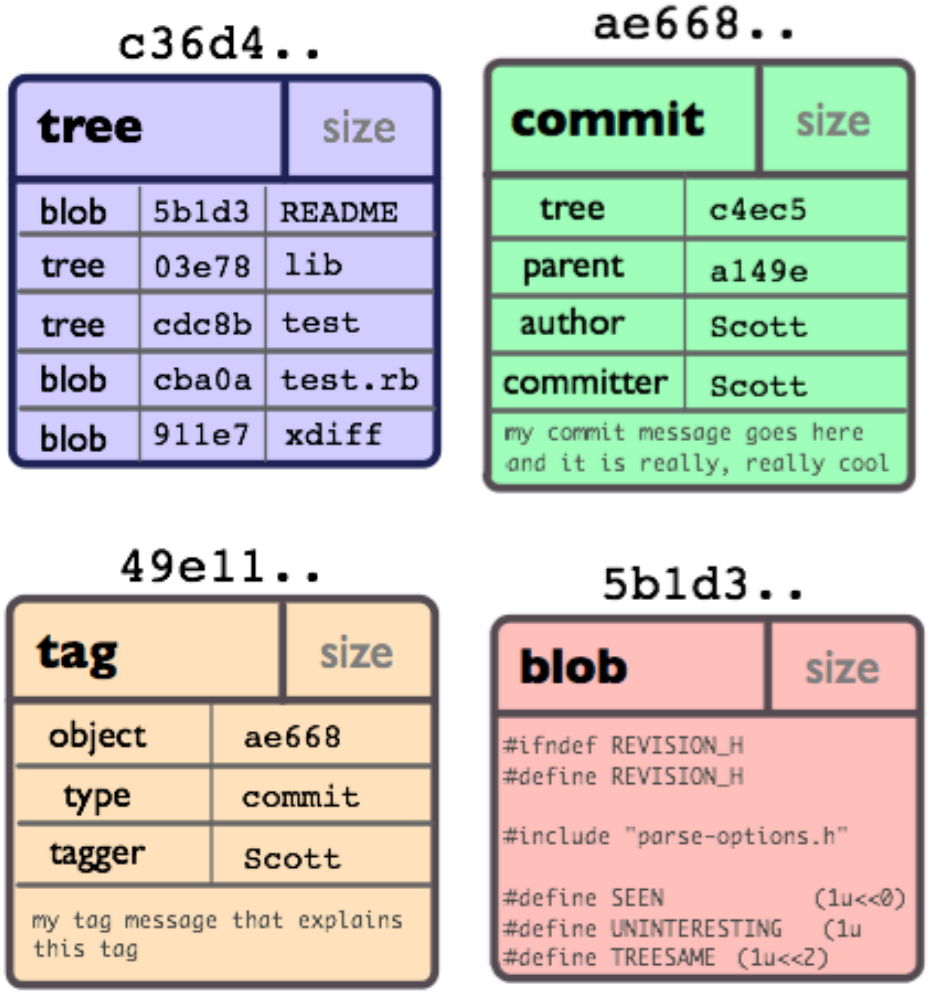

Abbildung: Die verschiedenen Objekte (Commit, Tree, Tag und Blob) in Git

Objekte in Git

Blob Die eigentliche Datei, SHA1-Wert und einige Metadaten.

Tree ist eine Sammlung von Blobs. Ein Tree ist damit äquivalent zu einem Verzeichnisordner

Commit speichert die Commitdaten, User, Datum, Beschreibung und verweise auf Tree, Blob und Tag ab.

Tag verbindet die SHA1-Summe eines anderen Objektes mit einem beliebigen Namen.

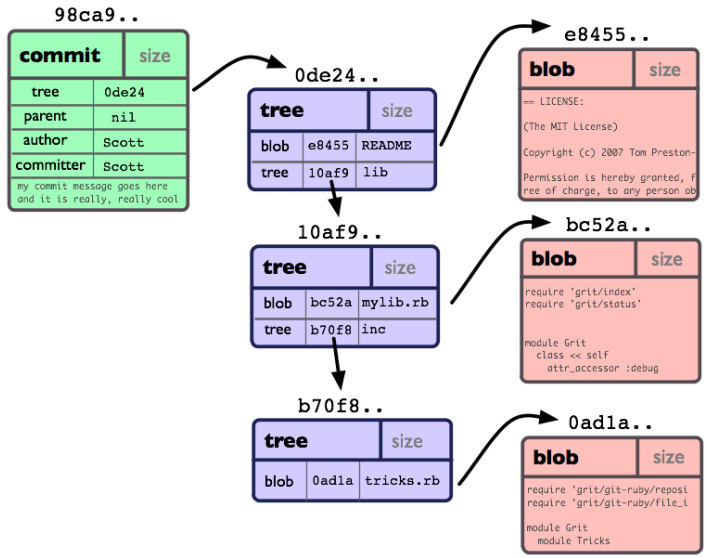

Abbildung: Die verschiedenen Objekte (Commit, Tree und Blob) in Git

History

Nach jeder abgeschlossenen Änderung werden diese in das VCS übertragen. Das VCS verbindet diese Commits miteinander in Form eines Graphen. Es wird ein gerichteter azyklischer Graph aufgebaut (Directed Acyclic Graph, DAG).

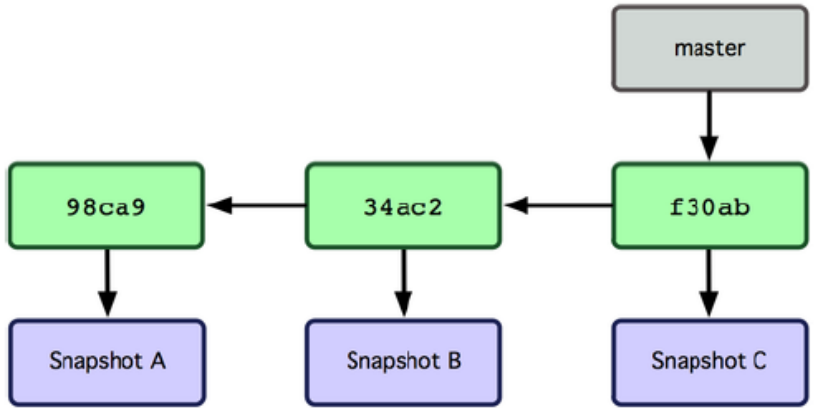

Graph

Ein *Graph* besteht aus den beiden Kernelementen *Knoten* und *Kante*. Ein Commit, Tag, Referenz oder andere Objekte werden immer durch einen Knoten im Graphen dargestellt. Die Kante wird durch einen Verweis auf ein oder mehrere Eltern-Objekt(e) dargestellt.

In Git hat jedes Objekt einen eindeutigen SHA1-Prüfsummen. Daraus ergibt sich eine kryptographisch gesicherte Integrität des Repositorys.

History als Graph: Von Branches, Merges und Tags

Branch entsteht wenn mehrere Versionen von einem Elternobjekt abhängen.

Tag ist der Name für eine bestimmte Version.

Merge führt den Parallelen Zweig in den Hauptzweig zurück.

master ist in Git der Name für den Hauptentwicklungszweig.

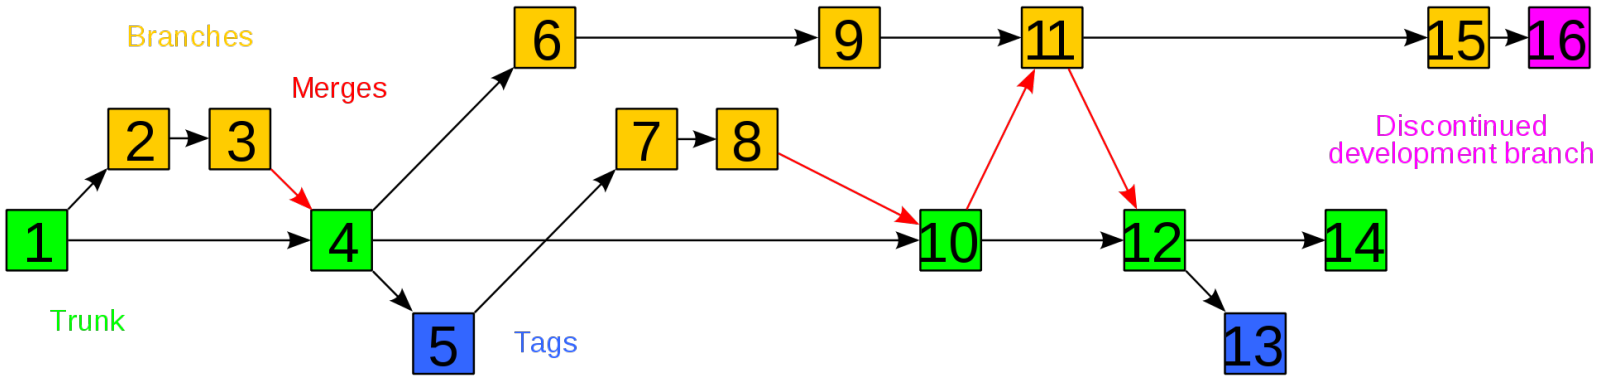

Abbildung: Der Graph bildet das gesamte Repository (Branches, Merges und Tags) ab. In Subversion: master = trunk.

GUI-Tools für Git

gitk, git-gui, meld, TortoiseGit

Repository Tool: *gitk*

gitk

In Tcl programmiertes grafisches Frontend zur Anzeige des Repositories.
Ist im Git Standard Umfang enthalten und somit **immer** vorhanden.
Ermöglicht einen schnellen Überblick über die History, Commits, Diffs, Tags und die Struktur des Repositories.

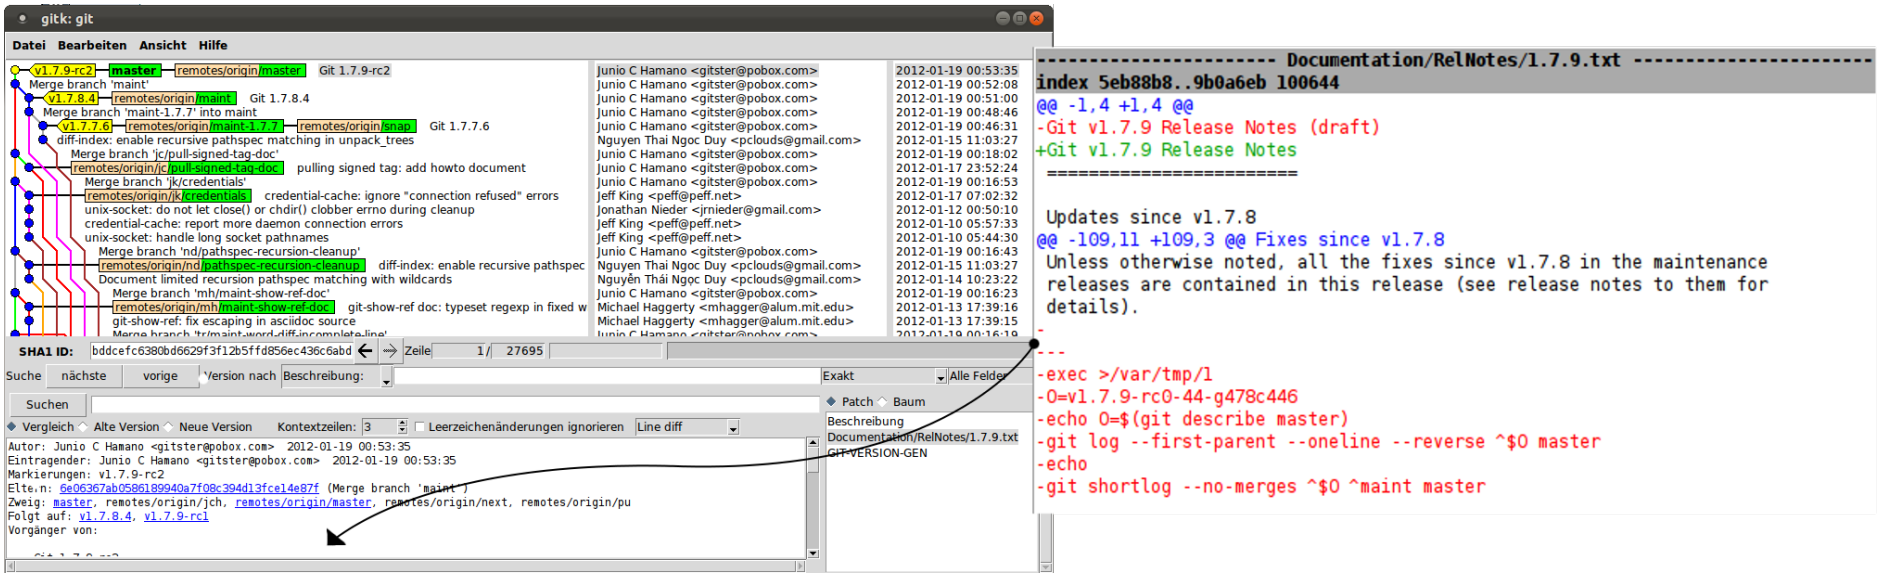

Abbildung: *gitk*: einfach, übersichtlich und immer da!

Commit Tool: *git-gui*

git-gui

Einfaches grafisches Programm um Änderungen bereitzustellen und einen Commits zu erstellen.

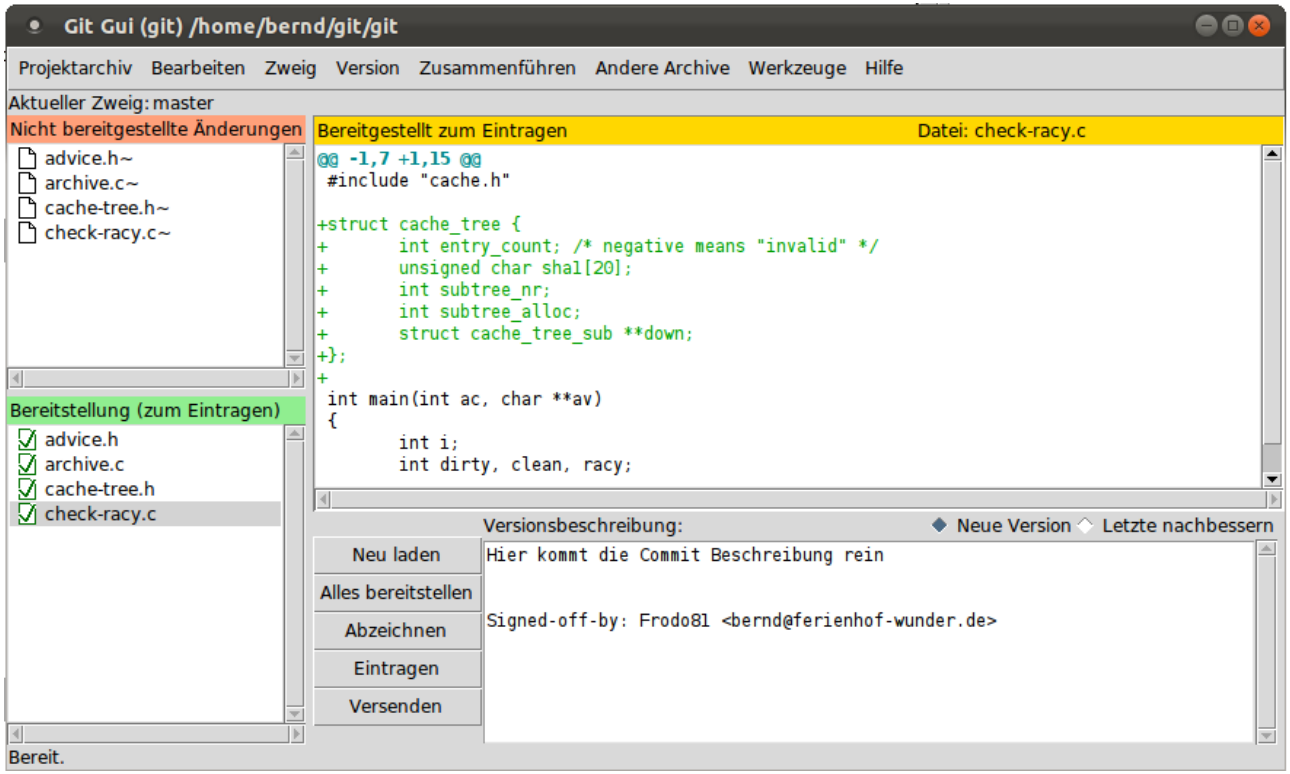

Abbildung: *git-gui*: Frontend für die Erstellung eines Commits. Ist wie *gitk* im Standardumfang enthalten.

Diff-Tool: meld

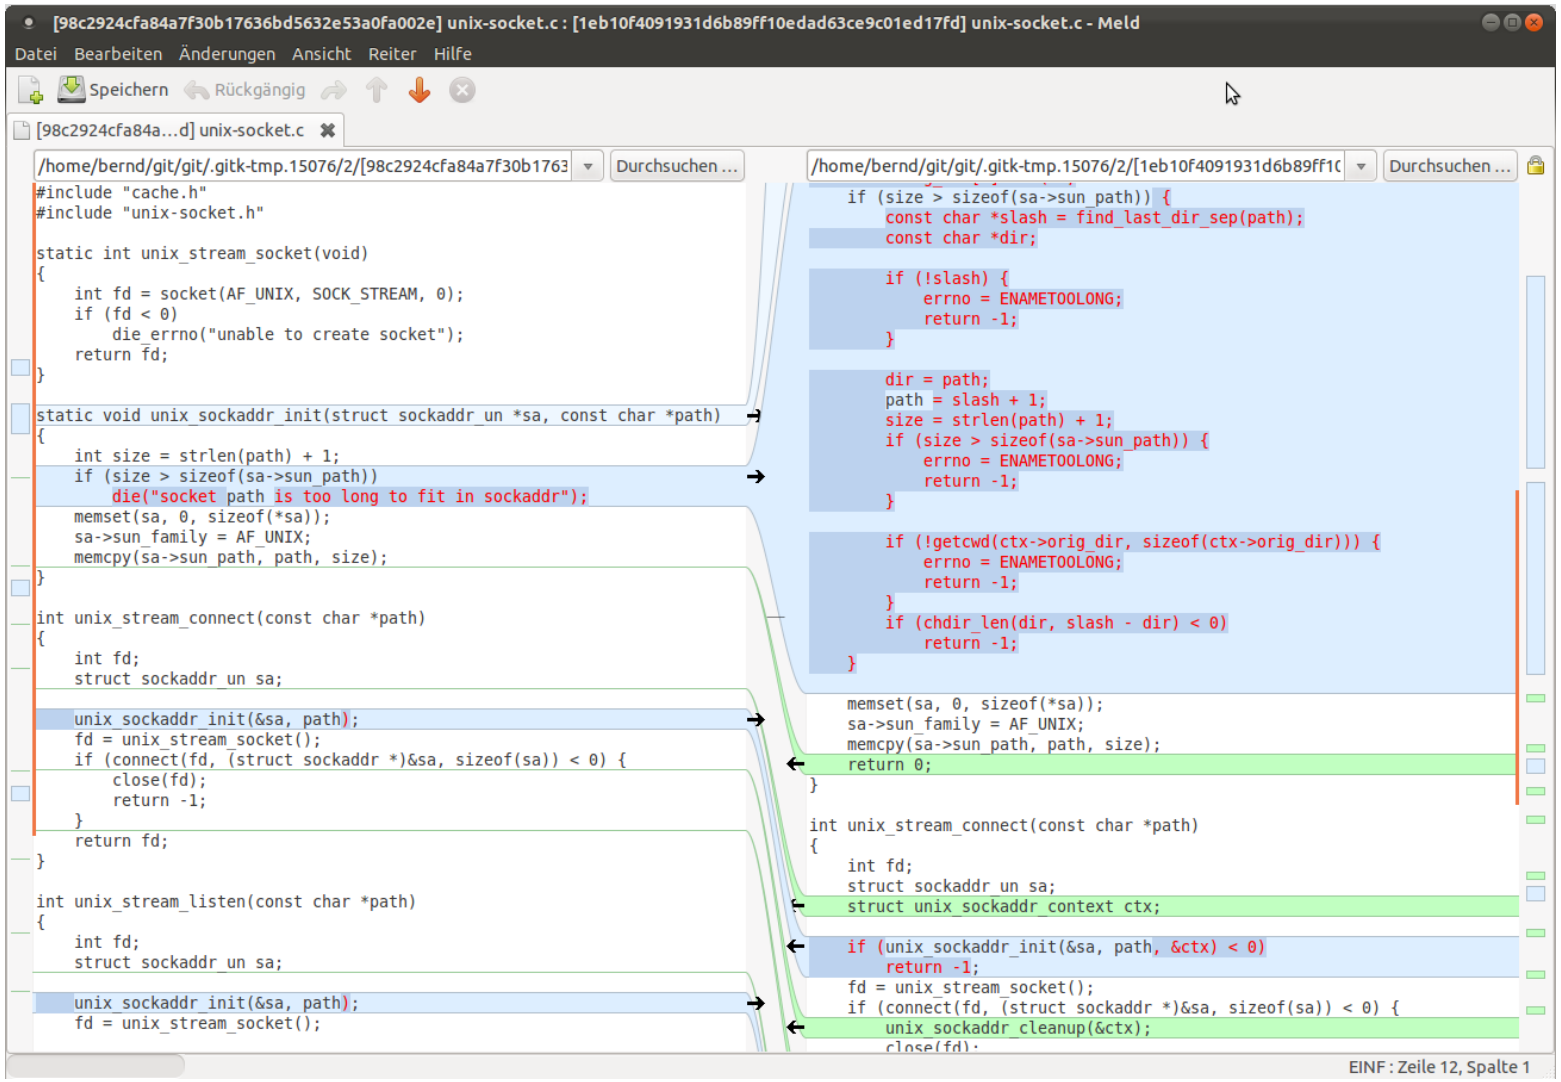

Abbildung: *meld*: einfach, übersichtliches diff-Tool

TortoiseGit

TortoiseGit ist ein kostenloser und freier Windows Client für Git.

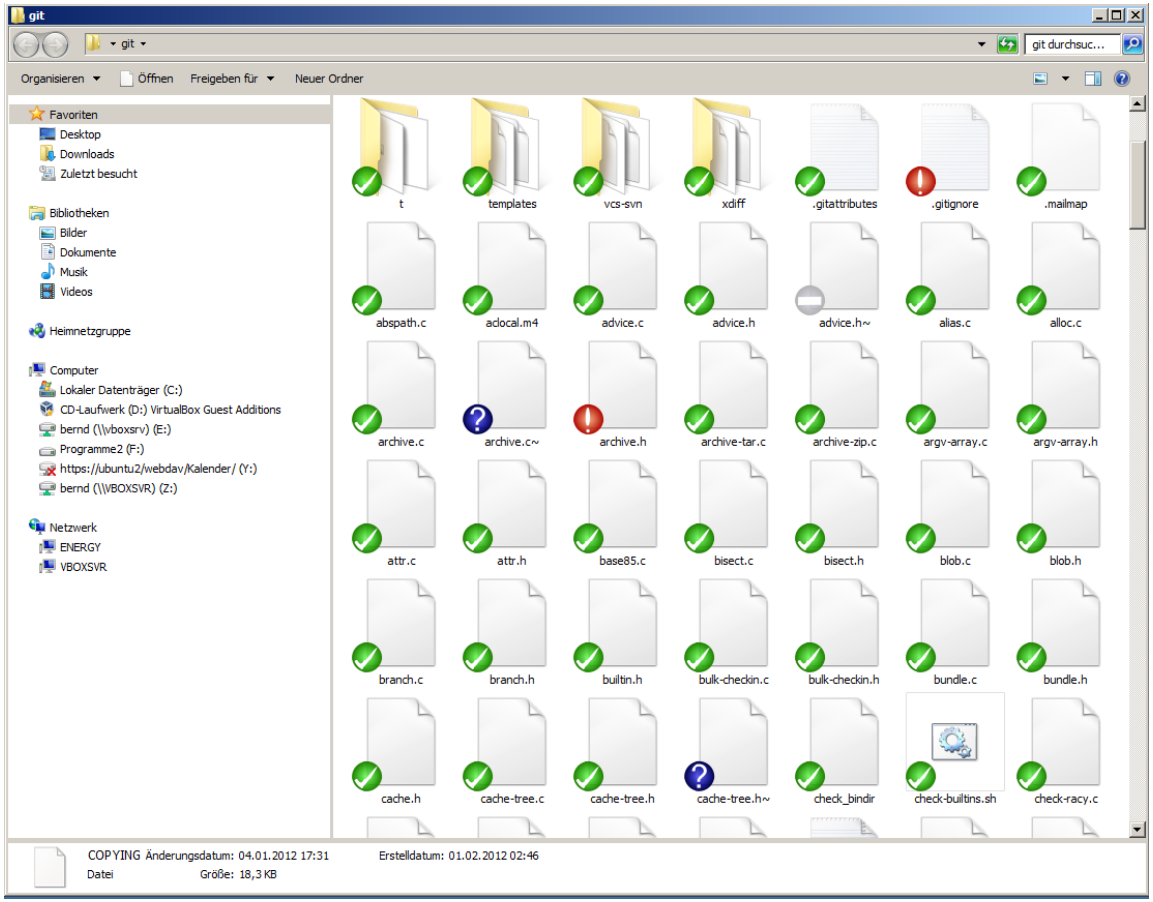

Abbildung: *tortoiseGit*: Git Integration in den Windows Explorer

TortoiseGit 2

GIT-Befehle in das Kontext Menü im Windows Explorer integriert:

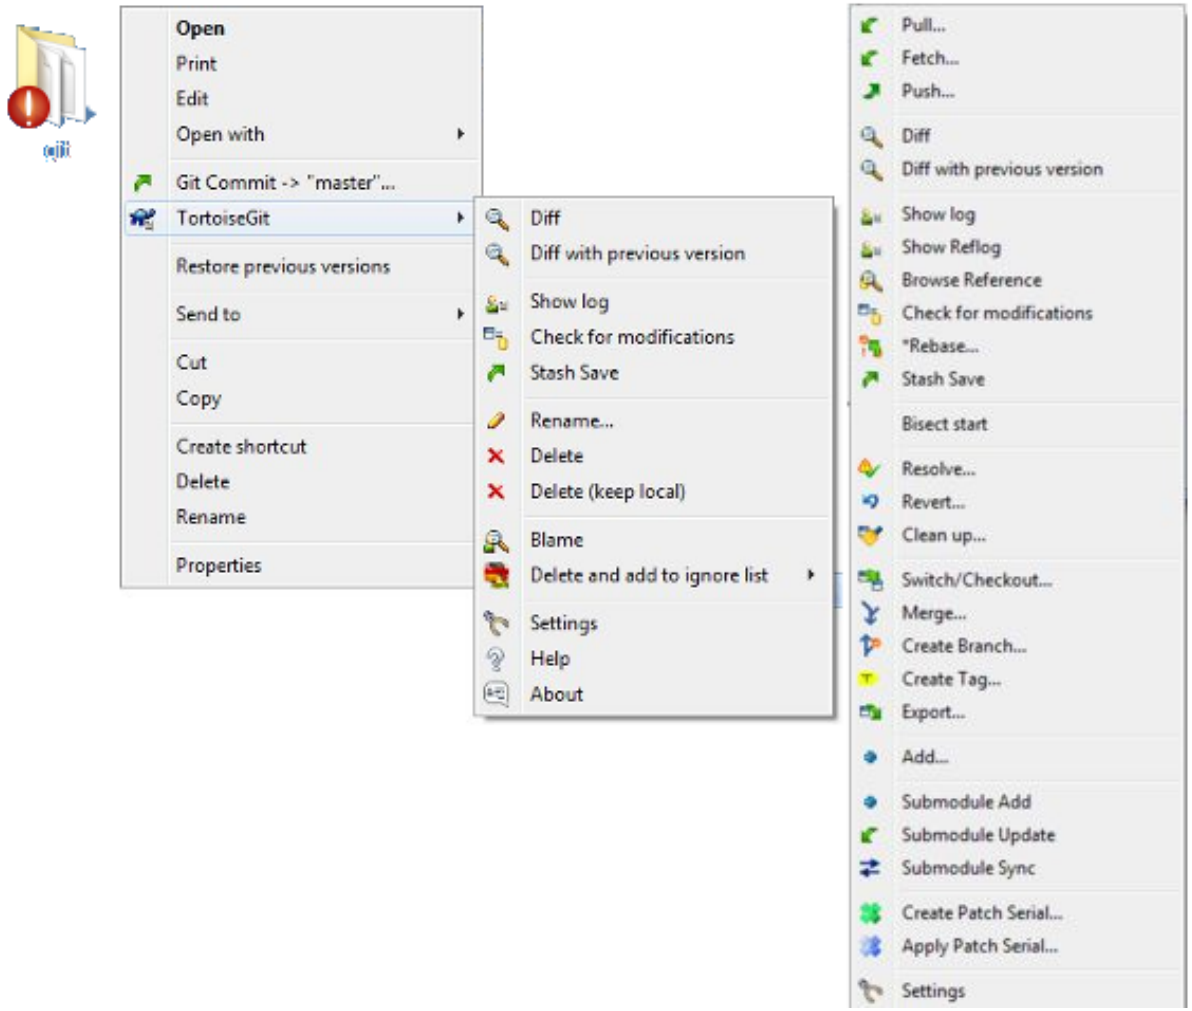

Abbildung: Git Befehle im Kontextmenü des Explorers. Es werden nur die nutzbaren Befehle angezeigt.

TortoiseGit 3

Als erstes sollte man seine Benutzerdaten eintragen:

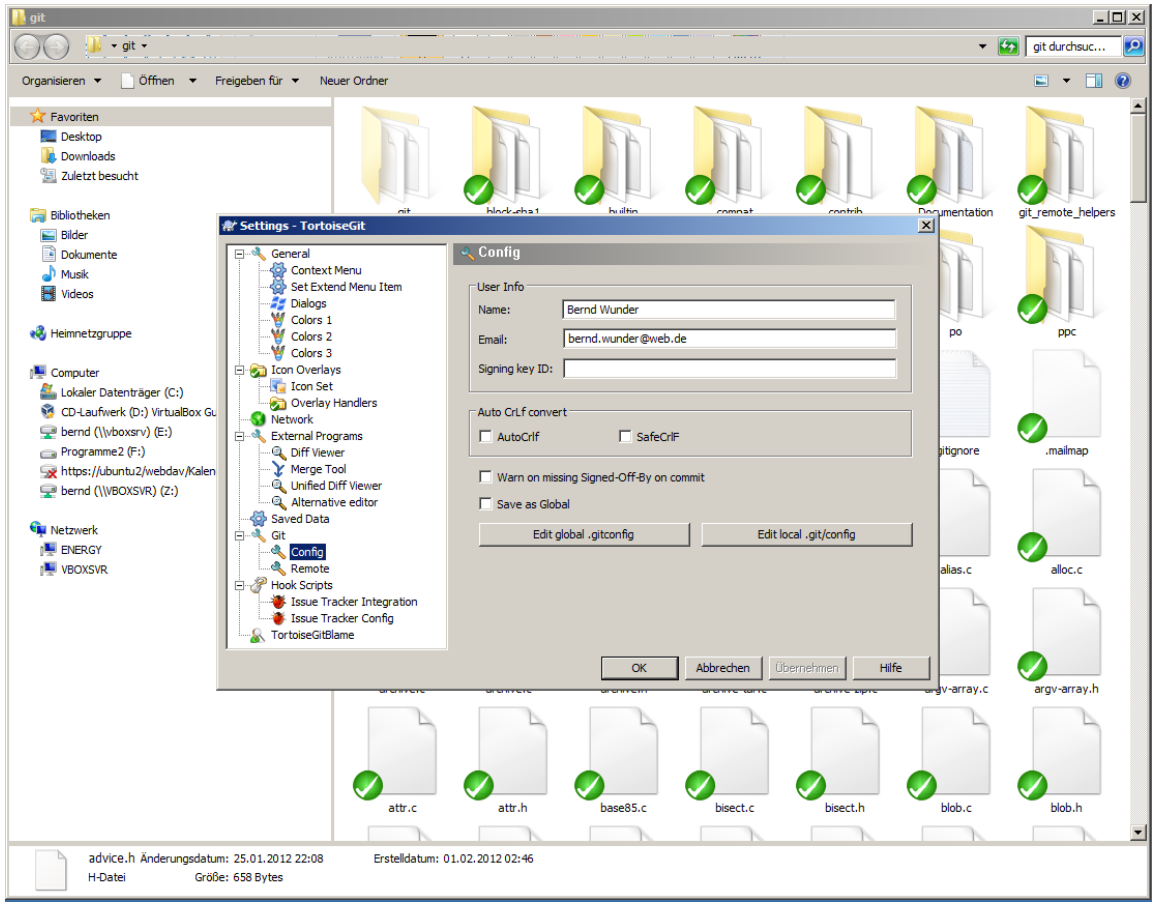

Abbildung: Unter **Settings** kann man sollte man Benutzer und Email einstellen!

TortoiseGit 4

Mit den **Commit...** Button kann man ganz einfach den aktuellen Stand sichern:

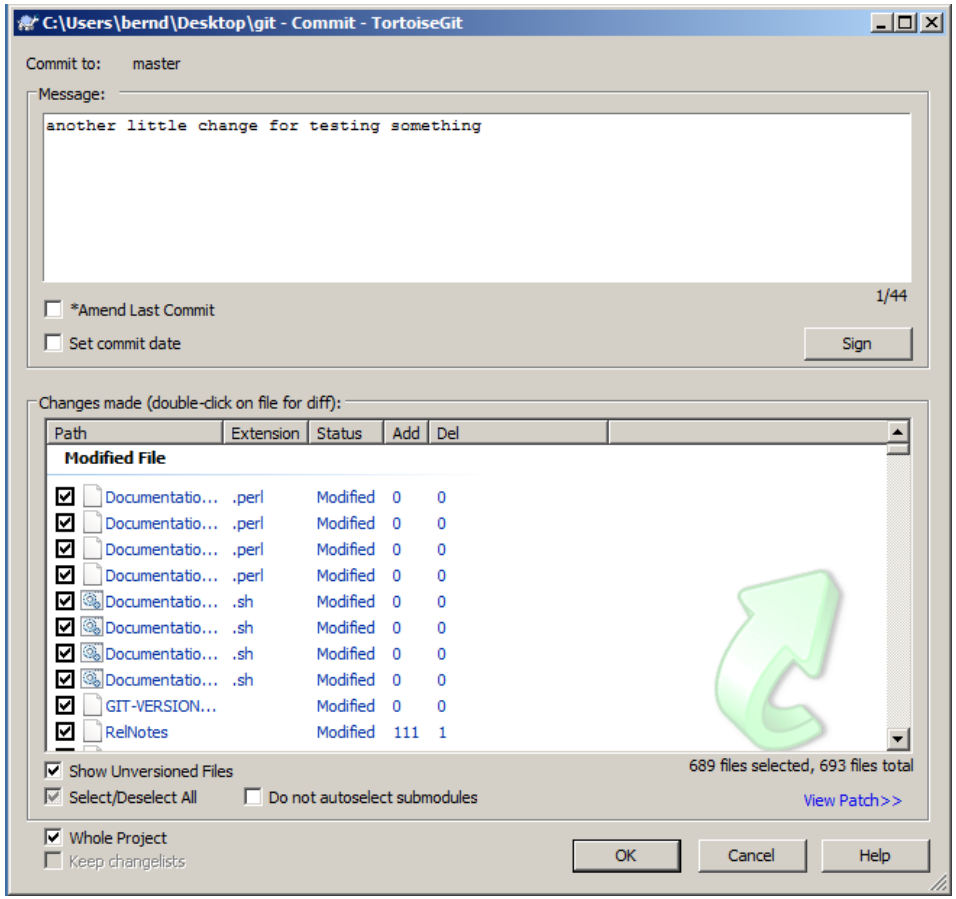

Abbildung: TortoiseGit bietet die Möglichkeit nur die ausgewählten Dateien in einen Commit zusammenzufassen!

TortoiseGit 5

Merkmale von TortoiseGit:

1. Intuitiv und schnell zu erlernen
2. gute Integration in Windows durch Overlays
3. add, commit und push mit einem Dialog
4. Unterstützt gängige Speicherorte, u.a. Netzlaufwerke, GitHub, ...

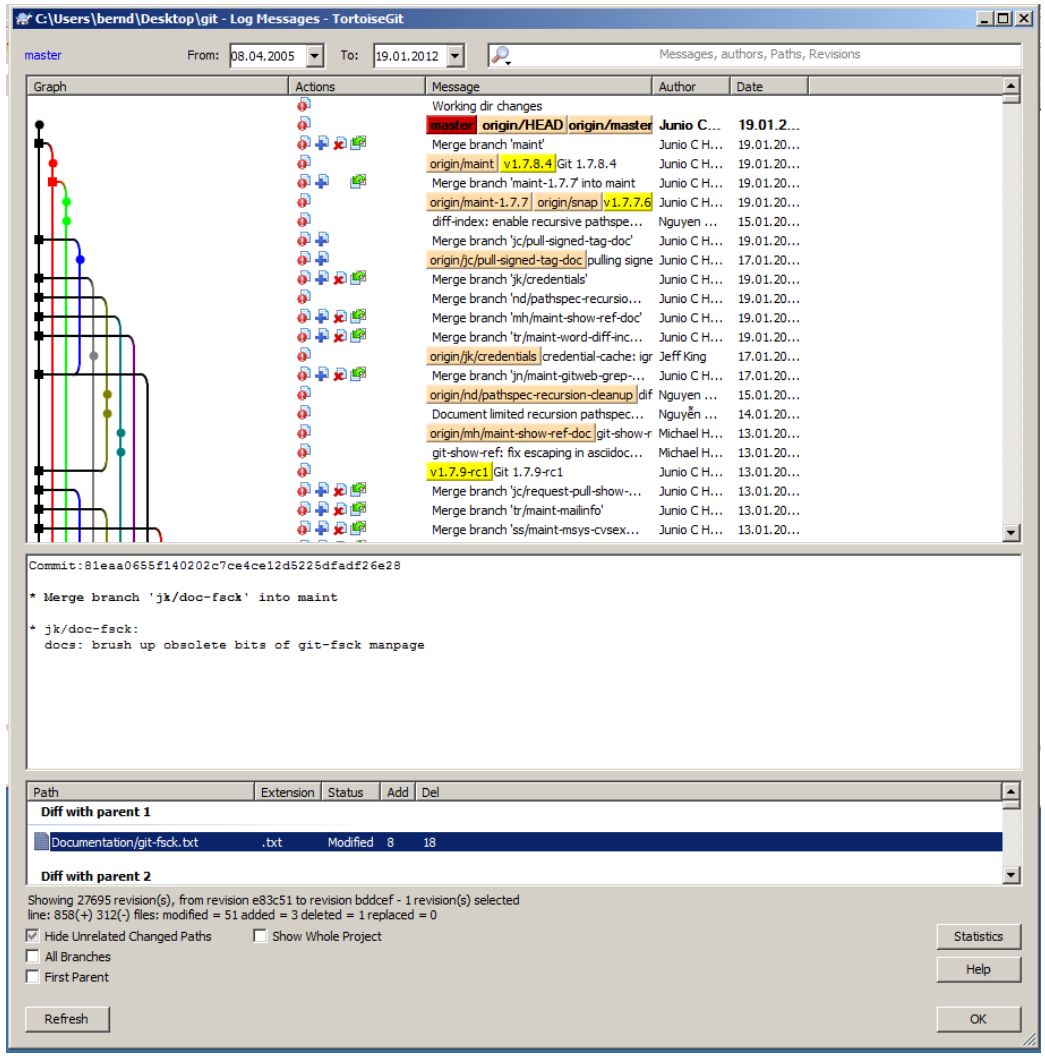

Befehle

Getting Started

Als erstes sollte man Git seine Identiät bekannt machen:

```
git config --global user.name "Bernd Wunder"
git config --global user.email bernd.wunder@leb...
```

neues Repository im aktuellen Verzeichnis anlegen:

```
git init
```

eine Datei dem Repository hinzufügen:

```
git add /Pfad/Zur/Datei
```

alle Dateien im aktuellen Verzeichnis dem aktuellen Repository hinzufügen:

```
git add .
```

einen Commit ausführen:

```
git commit -m "Initial Commit"
```

Befehle 2

Remotes

Unter einem Remote versteht man eine entfernte Quelle. Der **git remote** Befehl dient zum Verwalten der Remotes:

```
bernd@power:~$ git remote
origin
power
```

oder ausführlicher mit:

```
bernd@power:~$ git remote -v
origin   /media/Transcend/Versionsverwaltung_mit_GIT/ (fetch)
origin   /media/Transcend/Versionsverwaltung_mit_GIT/ (push)
```

einen neuen Alias auf einen entfernten Remote hinzufügen:

```
git remote add newName https://www.weitWeg.de/Repository.git
```

Befehle 3

branch

Für die Erstellung eines neuen Zweiges (branch):

```
git branch lilly
```

Eine ausführliche Übersicht über die vorhandenen Branches:

```
bernd@Power:~$ git branch -v
* lilly   98a74d9 Some further commands
  master e2694e7 Some explaination about commands
```

Umbenenen des aktuellen Zweiges nach isabella:

```
git branch –m isabella
```

In einen anderen Zweig wechseln und auschecken (hier in master):

```
git checkout master
```

Sonstiges

Protokolle, .gitignore, Kooperation mit anderen VCS

Protokolle

Protokolle

Zwischen den Repositories können Daten mit einer Reihe unterschiedlicher Protokolle ausgetauscht werden:

- http (Webserver)
- https (Webserver, verschlüsselt)
- ftp (Webserver)
- ssh (Secure Shell, verschlüsselt, admins)
- rsync (GNU/Linux, Synchronisationsprotokoll mit Delta-Kodierung)
- git (git-Protokoll, gepackt)
- email (Patches via Email, Mailing-Liste)

Protokolle - Beispiele

clone-Befehl

Um ein entferntes Repository zu klonen:

```
git clone <remote> <local>
```

git-Quellcode von github.com klonen

über das git-Protokll von github.com kopieren:

```
git clone git://github.com/gitster/git.git git
```

und über https:

```
git clone https://github.com/gitster/git.git git
```

oder von einer localen Quelle:

```
git clone /home/julia/git git
```

.gitignore

Um bestimmte Dateien oder Muster nicht unter Versionsverwaltung zu stellen kann man die ***.gitignore*** Datei verwenden. Alle darin enthaltenen Dateien oder Muster werden ignoriert.
In der Regel werden bei einem Buildprozeß Hilfsdateien angelegt die nur für die Tools notwendig sind. Diese Dateien möchte man in der Regeln nicht versionieren. Auch Projektdateien und Konfigurationsdateien von der Entwicklungsumgeben haben in der Versionsverwaltung nichts zu suchen, da diese sich mit unterschiedlichen Benutzern oder Programmen ändern.

Die ***.gitignore*** Datei kann sich selbst im entsprechenden Projektordner befinden und unter Versionsverwaltung gestellt werden. Daneben kann man zusätzlich eine eigene Datei die nicht im unter Versionsverwaltung steht und sich sinnvollerweise im eigenen Home Verzeichnis befindet mit einbinden:

```
git config --global core.excludesfile ~/.gitignore
```

.gitignore 2

.gitignore

Eine ***.gitignore*** Datei sieht nun z.B. wie folgt aus:

```
# do not versioning all LaTeX files!
*.log
*.out
# ...

# Verzeichnis komplett ignorieren
~/temp/

# ! invertiert den Wunsch, so wird die Datei
# ImportendLogging.log doch von git verwaltet,
# obwohl obiges Muster *.log zutrifft.
!ImportendLogging.log
```

Kooperation mit anderen VCS

Git bietet sehr gute kooperation mit anderen Systemen wie Basar, Mercurial, SVN, CVS

- git-svn -> besser wenn Hauptrepository in GIT
- subgit (Subversion (SVN) + Git) -> besser wenn Hauptrepository in SVN
- git-cvs
- hg-git
- git-hg
- git-bzr
- ...

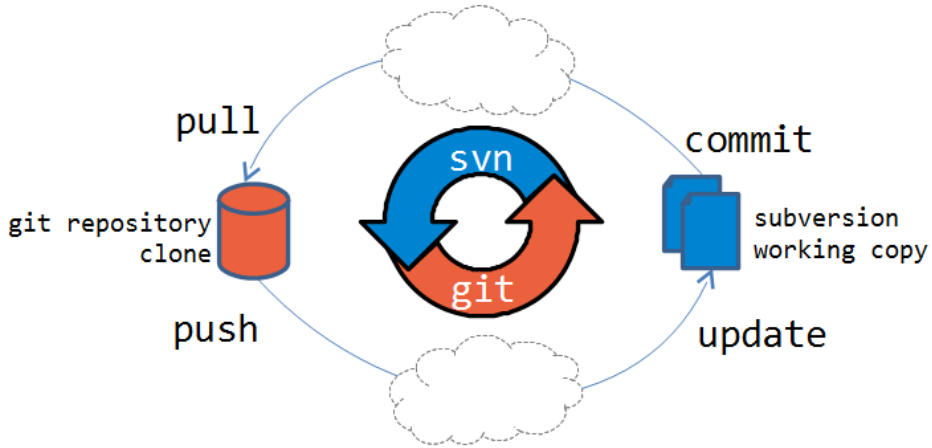

Abbildung: Git arbeitet gut mit anderen VCS zusammen, wie z.B. mit Subversion (SVN)

Submodules

Unter einem Submodul versteht man ein Repository, das sich in einem Unterordner eines anderen Repositories befindet. Dies bietet sich z.B. an um eine eigene Bibliothek auf eine *intelligente* Art einzubinden.
Bindet man eine externe Bibliothek ein und führt Anpassungen durch, können folgende Probleme auftretten:

- Einbinden einer statischen festen Version: Durch die Anpassungen wird ein folgen des Mainstreams sehr aufwendig.
- Bibliothek als gegeben voraussetzen: Anpassungen an der Bibliothek sind damit ausgeschlossen.

Durch die Verwendung von Submodules in Git kann man die beiden beschriebenen Probleme umgehen.

Quellen & Literatur

 *Bazaar vs Git*

 *Versionsverwaltung*

 *Pro Git - Scott Chacon*

 *Version Control System Comparison*

 *RCS HowTo*

 *Why Switch to Bazaar?*

 *Bazaar*

 *EGit User Guide*

Quellen & Literatur 2

- *Git*
- *Github*
- *The Git Community Book*
- *Git Projekt Page*
- *Git - SVN Crash Course*
- *Warum Git besser als X ist*
- *SVN und GIT im Vergleich*
- *Renaming is the killer app of distributed version control*
- *Scrum*
- *Über den Status quo verteilter Versionsverwaltungssysteme*